

Universitatea „Alexandru Ioan Cuza” din Iași
Facultatea de Economie și Administrarea Afacerilor
Master Data Mining

Proiect Rețele Neurale

**Analiza predictivă a îmbunătățirii nivelului de educație ca
urmare a metodelor de predare online**

Student: Dancă Alexandra-Simona

310440105001SM211018

DM21

CUPRINS

1.	Prezentarea temei de cercetare analizate	3
1.1.	Fenomenul economic	3
1.2.	Factorii de influență.....	4
2.	Prezentarea datelor	6
3.	Tipul aplicației	9
4.	Analiza exploratorie a datelor	11
4.1.	Analiza grafică a variabilelor numerice	12
4.2.	Analiza grafică a variabilelor nenumerice.....	13
4.3.	Identificarea outlierilor și tratarea acestora.....	14
5.	Alegerea tipurilor de rețele neurale și prezentarea structurii acestora (SPSS)	15
5.1.	Multilayer Perceptron.....	15
5.2.	Radial Bias Function	17
6.	Analiza performanței rețelelor (SPSS).....	20
6.1.	Analiza performanței rețelei Multilayer Perceptron cu un singur strat ascuns și 8 neuroni pe stratul ascuns.....	20
6.2.	Analiza performanței rețelei Multilayer Perceptron cu 2 straturi ascunse: primul strat ascuns are 8 neuroni, iar al doilea strat ascuns are 6 neuroni.....	21
6.3.	Analiza performanței rețelei Radial Bias Function cu 7 neuroni pe stratul ascuns	22
6.4.	Analiza performanței rețelei Radial Bias Function cu 17 neuroni pe stratul ascuns.....	23
7.	Alegerea tipurilor de rețele neurale și prezentarea structurii acestora (R)	24
7.1.	Rețea neurală în R cu un strat ascuns și 4 neuroni pe stratul ascuns	24
7.2.	Rețea neurală în R cu un strat ascuns și 2 neuroni pe stratul ascuns	25
7.3.	Rețea neurală în R cu un strat ascuns și 2 neuroni pe stratul ascuns	25
7.4.	Rețea neurală în R cu 2 straturi ascunse și 2 neuroni pe stratul H1 și 2 pe H2	26
8.	Analiza performanței rețelelor (R)	27
9.	Predicția rețelei neurale.....	28
	Concluzii	29
	ANEXĂ	30
	Bibliografie	34

1. Prezentarea temei de cercetare analizate

1.1. Fenomenul economic

Schimbările care au avut loc în ultimii ani la nivel global au avut un impact major asupra instituțiilor de învățământ și le-au obligat să se adapteze pentru nevoile de informare și comunicare dintre instituții și studenți. Dezlănțuirea pandemiei COVID-19 la începutul anului 2020, a creat o imensă perturbare în toate aspectele vieții sociale. Conform UNESCO, aproximativ 72,9% din populația studenților din lume, înscrisă în școli, universități și colegii, a fost afectată de barajul pandemiei (Mai 2020) ¹ și a trebuit să se adapteze restricțiilor instituțiilor fizice cu scop educativ. În acest context, editorii educaționali au recunoscut momentul potrivit pentru a înainta și a susține educația la domiciliu într-o varietate de moduri. Unii au deschis conținut educațional și de cercetare pentru a fi consultat și descărcat gratuit, alții au dezvoltat platforme speciale pentru diseminarea conținutului științific sau au încurajat accelerarea inițiativelor de „acces liber” ².

Mediul online oferă universităților o facilitate de a furniza informații exacte și de actualitate precum și o comunicare simultana cu grupuri virtuale. În prezent există mai multe rețele de socializare precum, Facebook, Instagram, YouTube, Windows Live Spaces, LinkedIn, Twitter, OpenID ș.a.

Sistemul de e-learning ajută studenții și profesorii și le permite să continue procesul de învățare în orice moment disponibil prin resurse digitale. Diferă de învățarea tradițională prin faptul că nu li se cere elevilor și profesorilor să fie în aceeași clasă în timpul procesului de predare. Mai mulți termeni standard sunt folosiți interschimbabil pentru e-Learning, cum ar fi învățarea la distanță și învățarea online³.

Abu Tair și El-Halees (2012)⁴ au analizat datele studenților prin crearea arborilor de decizie, făcând o asociere sau reguli secvențiale de minerit și clasificând studenții pentru a-și îmbunătăți performanța și a lua decizii fructuoase în domeniul fascinant de cercetare. Romero și

¹ UNESCO. Education: From Disruption to Recovery. Disponibil online: <https://en.unesco.org/covid19/educationresponse>

² International Publishers Association. Publishers Amid COVID-19 Pandemic. Disponibil online: <https://www.internationalpublishers.org/covid-reaction/168-covid-19/966-publishers-act-amid-covid19-pandemic>

³ AlHamad AQM, *Acceptance of e-learning among university students in UAE: a practical study*. Int J Electr Comput Eng, 2020, Vol. 10(4), pp. 3660–3671

⁴ Abu Tair, M. M. & El-Halees, A. M., *Mining educational data to improve students' performance: a case study*. Mining educational data to improve students' performance: a case study, Vol. 2(2)

Ventura (2010)⁵ au concluzionat că multe tehnici de extragere a datelor sunt folosite pentru a genera modele, reguli, clasificare și predicție specifice pentru a ajuta studenții în viitor.

1.2. Factorii de influență

Potrivit unui studiu realizat de Cradler, McNabb, Freeman și Burchett, consideră că utilizarea tehnologiei precum internetul este unul dintre factorii care pot influența pozitiv sau negativ performanța educațională a elevilor. Elevii petrec prea mult timp pe site-uri de socializare precum Facebook și nu au suficient timp pentru a studia, ceea ce îi duce pe studenți la performanțe slabe în timpul liceului și, în cele din urmă, se consideră dificil de supraviețuit în studiile superioare. EDM poate detecta acest model de comportament slab la momentul potrivit pentru a maximiza notele elevilor și pentru a minimiza rata de eșec a studenților⁶.

Un alt studiu realizat de Sockheyand și Okazaki arată că rețelele sociale influențează pozitiv elevii. Elevii folosesc rețelele sociale în scopuri academice pentru a-și îmbunătăți performanța. Atât profesorii, cât și studenții pot folosi rețelele sociale ca instrument de predare și învățare pentru ușurință și îmbunătățirea procesului de educație⁷.

Un alt studiu realizat în 2018 de Faheem, Shah și Butt a relatat că în învățământul superior se folosesc abordări de datamining și creează o cercetare educațională parțială atractivă. Aceste abordări sunt utilizate pentru identificarea și găsirea de date semnificative din date mari fără sens. Folosind o metodă de extragere a datelor supravegheată, găsim rezultatele progresului elevilor. Găsirea progresului elevului este utilă pentru organizațiile educaționale actuale. Scopul de bază al studiului este realizarea unui model cu ajutorul metodelor de clasificare. Acest model analizează performanța studenților din Malaezia. Acest model este folosit pentru a găsi cele mai importante caracteristici din setul mare de date. Multe abordări care sunt KNN, Bayes naiv, DT și abordări de regresie logistică sunt utilizate pentru a analiza performanța rezultatelor academice ale studenților. Aceste abordări se bazează pe măsurarea acurateței, precizia, reamintirea și curba ROC. Ieșirea

⁵ Romero, C., Ventura, S., *Educational data mining: a review of the state of the art*. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2010, Vol. 40(6), pp. 601–618.

⁶ Cradler, J. , McNabb, M., Freeman, M., Burchett, R., *How does technology influence student learning*, Learning and Leading with Technology, 2002 vol. 29, no. 8, pp. 46–49.

⁷ Sockheyand and, P., Okazaki, T., *Developing web-based supportsystems for predicting poor-performing students using educational data mining techniques*, Studies, 2020, Vol. 11, no. 7.

care arată algoritmul naiv Bayes este mai bună. NB dezvăluie atribute importante care sunt folosite pentru a găsi studenți excelenți ale căror note sunt A+ și A⁸.

Studiul realizat de Oyelade, Oladipupo și Obagbuwa a declarat că arborele de decizie este cel mai larg utilizat algoritm de clasificare supravegheată. Crearea pasului său este rapidă și ușoară. Clasificatorul DT este aplicat pe orice câmp. Setul de date calitative pentru studenți este colectat din dataminingul educațional. Pe setul de date se aplică diferiți algoritmi de arbore de decizie și se compară performanța. Acești algoritmi sunt CART, C4.5 și ID3. Rezultatul de contrast arată că indicele Gini al CART influențează informațiile privind raportul de câștig al ID3 și C4.5. Performanța și corectitudinea algoritmului CART sunt mai mari decât ID3 și C4.5, deoarece rezultatele algoritmului DT demonstrează că performanța elevului este influențată de caracteristicile calitative⁹.

Așadar, până acum au fost efectuate numeroase cercetări pentru a prezice performanța studenților folosind data mining. Dar puțini dintre ei au evidențiat trăsăturile importante care afectează performanța educațională a elevilor.

⁸ Faheem, M., Shah, S., B., H., Butt, R., A., *Smart grid communication and information technologies in the perspective of Industry 4.0: opportunities and challenges*, Computer Science Review, 2018, Vol. 30, pp. 1–30.

⁹ Oyelade, O., J., Oladipupo, O., O., Obagbuwa, I., C., *Application of k means clustering algorithm for prediction of students academic performance*, 2010 .

2. Prezentarea datelor

Baza de date utilizată în această lucrare este obținută de pe <https://www.kaggle.com/datasets/jehanbathena/online-survey-data-of-bangladeshi-students>.

Datele au fost obținute de pe site-ul Harvard Dataverse care este un depozit de date gratuit, deschis tuturor cercetătorilor din orice disciplină.

Principala preocupare a proiectului va fi observarea rezultatelor pe care elevii le au după educația online și care sunt factorii care au influență asupra acesteia.

Baza de date inițială conține 17 variabile, atât numerice, cât și nenumerice pentru 8783 de observații.

	Level of study?	Age?	Used smartphone/computer/laptop previously before online class?	Result increased after online education (comparatively)?	Knowledge increased after online education (comparatively)?	Happy with online education?	Education Institute Area?	Have Internet availability?	Broadband / Mobile Internet?	Total hours of study before online education?	Total hours of study after online education?	Class performance increased in online education?	Institute Type	Current location (During Study) ?	Gender	Faced any issue with online class?	Preferred device for an online course
1	Upto HSC	20	Yes	No	Yes	No	Urban	No	Broadband	4	3	No	Public	Rural	Male	Yes	Mobile
2	Hons or Grater	25	No	No	No	No	Urban	No	Mobile Internet	4	4	No	Public	Rural	Male	Yes	Mobile
3	Hons or Grater	25	Yes	Yes	Yes	Yes	Rural	No	Mobile Internet	5	2	Yes	Public	Rural	Female	Yes	Computer
4	Upto HSC	21	Yes	Yes	No	Yes	Urban	Yes	Mobile Internet	5	3	No	Private	Urban	Male	Yes	Mobile
5	Hons or Grater	22	Yes	No	No	No	Rural	No	Mobile Internet	4	2	Yes	Public	Urban	Male	No	Mobile
6	Hons or Grater	25	Yes	Yes	Yes	No	Urban	Yes	Broadband	3	2	Yes	Private	Urban	Female	No	Computer
7	Hons or Grater	24	Yes	Yes	Yes	No	Rural	Yes	Broadband	5	3	Yes	Public	Urban	Female	Yes	Computer
8	Hons or Grater	24	Yes	Yes	No	Yes	Rural	No	Mobile Internet	4	3	Yes	Private	Urban	Female	No	Computer
9	Upto HSC	22	Yes	Yes	No	Yes	Urban	Yes	Broadband	6	3	Yes	Private	Urban	Female	Yes	Computer
10	Hons or Grater	21	Yes	Yes	No	No	Urban	No	Broadband	6	3	Yes	Private	Urban	Female	Yes	Computer
11	Hons or Grater	22	Yes	No	Yes	No	Urban	No	Mobile Internet	5	4	No	Public	Rural	Male	Yes	Mobile
12	Hons or Grater	24	Yes	N/A	Yes	No	Urban	Yes	Broadband	6	3	No	N/A	N/A	N/A	No	Computer
13	Hons or Grater	22	Yes	No	No	Yes	Urban	No	Mobile Internet	4	3	Yes	Private	Urban	Female	No	Mobile
14	Hons or Grater	22	No	Yes	Yes	Yes	Rural	Yes	Broadband	3	3	Yes	Public	Rural	Female	No	Computer
15	Hons or Grater	26	Yes	No	Yes	No	Urban	No	Mobile Internet	5	3	No	Private	Rural	Female	Yes	Computer
16	Hons or Grater	22	Yes	Yes	No	No	Urban	Yes	Mobile Internet	3	4	Yes	Private	Rural	Male	Yes	Computer
17	Hons or Grater	24	Yes	No	Yes	No	Urban	No	Mobile Internet	3	3	No	Private	Rural	Male	Yes	Computer
18	Hons or Grater	23	Yes	No	No	No	Urban	No	Mobile Internet	6	3	No	Private	Urban	Female	Yes	Mobile

Variabilele din figură au următoarea semnificație:

- **Level of study?** → Nivel de studiu;
- **Age?** → Varsta;
- **Used smartphone/computer/laptop previously before online class?** → Ați folosit smartphone sau laptop înainte de cursul online?;
- **Result increased after online education (comparatively)?** → Rezultatul a crescut după educația online?;
- **Knowledge increased after online education (comparatively)?** → Cunoștințele au crescut după educația online?;
- **Happy with online education?** → Mulțumit de educația online?;
- **Education Institute Area?** → Zona Institutului de educație;

- **Have Internet availability?**→ Aveți disponibilitate la internet?;
- **Broadband / Mobile Internet?**→ Internet pe bandă largă sau mobil?;
- **Total hours of study before online education?**→ Totalul de ore de studiu înainte de educația online?;
- **Total hours of study after online education?**→ Totalul de ore de studiu după educația online?;
- **Class performance increased in online education?**→ Performanța clasei a crescut în educația online?;
- **Institute Type**→ Tip institut de învățământ;
- **Current location (During Study) ?**→ Locația curentă în timpul studiului?;
- **Gender**→ Gen;
- **Faced any issue with online class?**→ Te-ai confruntat cu vreo problemă în timpul cursurilor online?;
- **Preferred device for an online course**→ Dispozitivul preferat pentru cursul online;

Pentru a realiza modelul de rețea neurală am ales din setul de date următoarele variabile: *Level of study, Age, Result increased after online education (comparatively), Knowledge increased after online education (comparatively), Happy with online education, Have Internet availability, Total hours of study before online education, Total hours of study after online education* și *Gender*.

Pentru a lucra și analiza mai ușor aceste variabile, au fost redenumite după cum urmează:

- *Level of study*: lvl_study
- *Age*: age
- *Result increased after online education (comparatively)*: result_a_onl
- *Knowledge increased after online education (comparatively)*: knowledge_a_onl
- *Happy with online education*: happy
- *Have Internet availability*: internet_acces
- *Total hours of study before online education*: total_h_study_b_onl
- *Total hours of study after online education*: total_h_study_a_onl
- *Gender*: gender

```
> head(data)
# A tibble: 6 x 9
  lvl_study age result_a_onl knowledge_a_onl happy internet_acces total_h_study_b_onl total_h_study_a_onl gender
  <chr>    <dbl> <chr>      <chr>      <chr> <chr>      <dbl>      <dbl>      <dbl> <chr>
1 Upto HSC 20 No      Yes        No    No        4          3 Male
2 Hons or Grater 25 No      No        No    No        4          4 Male
3 Hons or Grater 25 Yes     Yes        Yes    No        5          2 Female
4 Upto HSC 21 Yes     No        Yes    Yes       5          3 Male
5 Hons or Grater 22 No      No        No    No        4          2 Male
6 Hons or Grater 25 Yes     Yes        No    Yes       3          2 Female
```

Se observă că din 17 variabile cât erau inițial, am mai rămas cu 9. Urmează să verificăm dacă aceste variabile fac parte din clasa corectă.

```
> sapply(data,class)
      lvl_study      age      result_a_onl      knowledge_a_onl      happy      internet_acces      total_h_study_b_onl
"character"      "numeric"      "character"      "character"      "character"      "character"      "numeric"
```

Variabile precum *lvl_study*, *result_a_onl*, *knowledge_a_onl*, *happy*, *internet_acces* și *gender* sunt recunoscute ca fiind de tipul character. Acestea vor fi transformate în variabile de tip factor pentru analiza descriptivă a variabilelor. Atunci când o să ajungem la efectuarea rețelelor neurale, aceste variabile vor fi transformate în variabile numerice.

```
> sapply(data,class)
      lvl_study      age      result_a_onl      knowledge_a_onl      happy      internet_acces      total_h_study_b_onl
"factor"      "numeric"      "factor"      "factor"      "factor"      "factor"      "numeric"
```

Coloanele se aranjează astfel încât prima coloană să aibă variabila dependentă *lvl_study* urmată de celelalte variabile independente.

```
# aranjam coloanele
data <- subset(data, select=c(3,1,2,4,5,6,7,8,9))
```

Mai departe dorim să verificăm dacă există valori lipsă în baza noastră de date.

```
> colSums(is.na(data))
      result_a_onl      lvl_study      age      knowledge_a_onl      happy
      323          0          445          0          0
      internet_acces      total_h_study_b_onl      total_h_study_a_onl      gender
      0          0          0          676
```

Variabila *age* are 445 observații lipsă, *result_a_onl* are 323 observații lipsă iar *gender* are 676 valori lipsă. Aceste observații lipsă sunt eliminate cu ajutorul funcției *na.omit()*.

```
> dim(data)
[1] 7586 9
```

Din 8783 de observații au mai rămas 7586 după eliminarea rândurilor lipsă.

3. Tipul aplicației

Având în vedere cele menționate mai sus, prezenta lucrare își propune să realizeze o analiză predictivă a rezultatelor crescute după educația online a elevilor. Prin urmare, principalul obiectiv este de a construi o rețea neurală prin care se analizează influența asupra rezultatelor crescute după educația online a următoarelor:

- *Level of study*: lvl_study
- *Age*: age
- *Knowledge increased after online education (comparatively)*: knowledge_a_onl
- *Happy with online education*: happy
- *Have Internet availability*: internet_acces
- *Total hours of study before online education*: total_h_study_b_onl
- *Total hours of study after online education*: total_h_study_a_onl
- *Gender*: gender

Pentru prima rețea neurală, se va împărți setul de date în set de antrenare în care vor fi incluse 60% din înregistrările din bază, set de validare în care vor fi incluse 20% din înregistrările din bază și set de holdout în care vor fi restul înregistrărilor.

Matricea de confuzie clasifică datele reale în funcție de datele prezise. Aceasta evaluează predicțiile făcute pe datele de testare, adică numărul de predicții corecte făcute, precum și predicțiile greșite făcute pe date.

Mai departe observăm output-ul tabelului *Classification* pentru rețeaua Multilayer Perceptron cu un singur strat ascuns și 8 neuroni pe stratul ascuns. Această rețea este prezentată în detaliu în următoarele capitole din lucrare.

Classification					
Sample	Observed	Predicted		Percent Correct	
		No	Yes		
Training		0	1	117	0.0%
	No	0	10	1497	0.7%
	Yes	0	10	3380	99.7%
	Overall Percent	0.0%	0.4%	99.6%	67.6%
Testing		0	1	43	0.0%
	No	0	3	517	0.6%
	Yes	0	2	1103	99.8%
	Overall Percent	0.0%	0.4%	99.6%	66.3%
Holdout		0	0	50	0.0%
	No	0	2	528	0.4%
	Yes	0	2	1072	99.8%
	Overall Percent	0.0%	0.2%	99.8%	64.9%

Dependent Variable: result_a_onl

Pentru setul de date training interpretările sunt următoarele:

- TN: (No-No) 10 observații au fost previzionate corect pentru răspunsul No
- TP: (Yes-Yes) 3380 observații au fost previzionate corect pentru răspunsul Yes
- FP: (No -Yes) 1497 observații au fost previzionate incorect pentru răspunsul No
- FN: (Yes- No) 10 observații au fost previzionate incorect pentru răspunsul Yes

0,7% din observații au fost previzionate corect pentru răspunsul No. 99,7% din observații au fost previzionate corect pentru răspunsul Yes, iar în concluzie 67,6% din cazuri au fost previzionate corect.

Se poate remarca faptul că procentul de 67,6% de cazuri previzionate corect din tabelul de mai sus și procentul de 32,4% din tabelul model summary (prezentat în capitolul 6.1.) dau suma de 100%.

Pentru setul de date testing interpretările sunt următoarele:

- TN: (No-No) 3 observații au fost previzionate corect pentru răspunsul No
- TP: (Yes-Yes) 1103 observații au fost previzionate corect pentru răspunsul Yes
- FP: (No -Yes) 517 observații au fost previzionate incorect pentru răspunsul No
- FN: (Yes- No) 2 observații au fost previzionate incorect pentru răspunsul Yes

0,6% din observații au fost previzionate corect pentru răspunsul No. 99,8% din observații au fost previzionate corect pentru răspunsul Yes, iar în concluzie 66,3% din cazuri au fost previzionate corect.

Pentru setul de date testing interpretările sunt următoarele:

- TN: (No-No) 2 observații au fost previzionate corect pentru răspunsul No
- TP: (Yes-Yes) 1072 observații au fost previzionate corect pentru răspunsul Yes
- FP: (No -Yes) 528 observații au fost previzionate incorect pentru răspunsul No
- FN: (Yes- No) 2 observații au fost previzionate incorect pentru răspunsul Yes

0,4% din observații au fost previzionate corect pentru răspunsul No. 99,8% din observații au fost previzionate corect pentru răspunsul Yes, iar în concluzie 64,9% din cazuri au fost previzionate corect.

4. Analiza exploratorie a datelor

În acest capitol se analizează fiecare variabilă în parte. Această analiză calculează statistici, construiește grafice și identifică valorile extreme.

Pentru început, se va face o analiză succintă pentru variabilele pe care nu o să le includ în analizele care urmează să fie făcute în capitolele următoare.

```
> summary(data_del)
device_b_onl area_institute internet_type class_perf institute_type area_study issues_onl_class pref_device
No :1158 Rural:1726 Broadband :4355 No :4695 Private:5205 Rural:3741 No :3046 Computer:5607
Yes :7437 Urban:6528 Mobile Internet:4428 Yes:4088 Public :2852 Urban:4316 Yes :5036 Mobile :3176
NA's: 188 NA's : 529 NA's : 726 NA's : 726 NA's: 701
```

Aceste variabile au fost stocate în `dataFrame`-ul `data_del` și au fost redenumite pentru a ușura citirea acestora. După apelarea funcției `summary()`, se poate remarca faptul că 5 variabile (`device_b_onl`, `area_institute`, `institute_type`, `area_study` și `issues_onl_class`) sunt compuse și din valori nule. Acestea nu au fost eliminate deoarece nu ne afectează în analizele care urmează să se efectueze.

Având în vedere output-ul obținut, se poate spune că cei mai mulți dintre studenți au folosit un dispozitiv precum telefonul sau tableta înainte de trecerea la educația online, pentru desfășurarea orelor online calculatorul este cel mai potrivit pentru ei, provin din mediul urban și folosesc atât internetul mobil cât și cel pe bandă largă iar performanța clasei nu este crescută în timpul educației online și mulți dintre aceștia întâmpină probleme în clasa virtuală. De asemenea, cea mai mare parte a institutelor care au acceptat învățământul online sunt din mediul urban și sunt private.

Pe parcursul acestei lucrări, toată atenția se va îndrepta către cele 9 variabile care au fost selecționate în capitolul 2.

```
> summary(data)
lvl_study age result_a_onl knowledge_a_onl happy internet_acces total_h_study_b_onl total_h_study_a_onl gender
Hons or Grater:4886 Min. :16.00 No :2359 No :4817 No :4877 No :2311 Min. :3.000 Min. :2.000 Female:3380
Upto HSC :2700 1st Qu.:22.00 Yes:5227 Yes:2769 Yes:2709 Yes:5275 1st Qu.:4.000 1st Qu.:2.000 Male :4206
Median :23.00 Median :5.000 Median :3.000
Mean :22.81 Mean :4.508 Mean :2.986
3rd Qu.:24.00 3rd Qu.:5.000 3rd Qu.:3.000
Max. :26.00 Max. :6.000 Max. :4.000
```

- **lvl_study**: 4886 de observații au nivelul de educație Hons or Grater (licență sau master) iar 2700 de HSC(învățământ secundar superior);

- **age**: vârsta minimă este de 16 ani, în timp ce cea maximă este de 26 ani. Vârsta medie este de aproape 23 ani.

- **result_a_onl**: 2359 de observații nu au avut o îmbunătățire a rezultatelor în educația online, în timp ce 5227 au observat o îmbunătățire;

- **knowledge_a_onl**: 4817 de observații nu au avut o îmbunătățire a cunoștințelor în educația online, în timp ce 2769 au observat o îmbunătățire;

- **happy**: 4877 de observații nu s-au bucurat de educația online, în timp ce 2709 au spus că s-au bucurat;

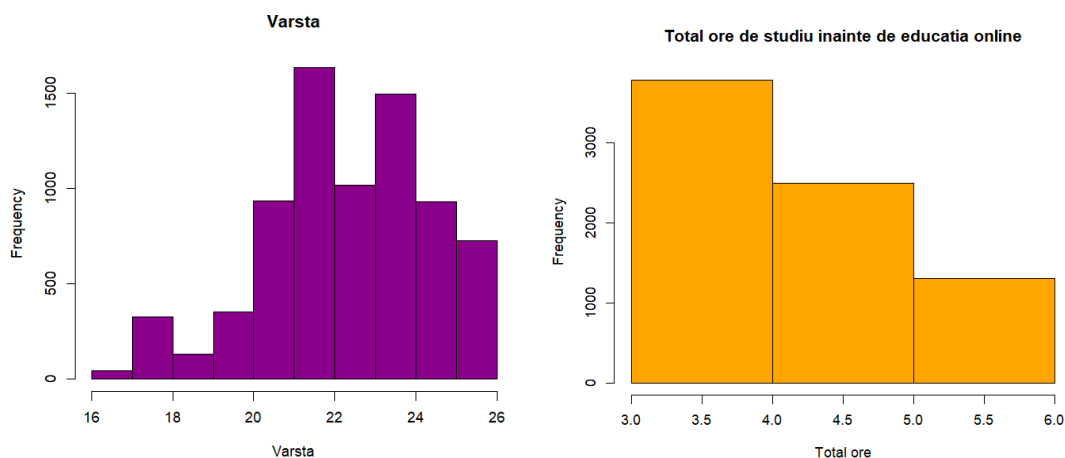
- **internet_acces**: 2311 de observații nu au avut acces la internet, în timp ce 5275 au avut acces;

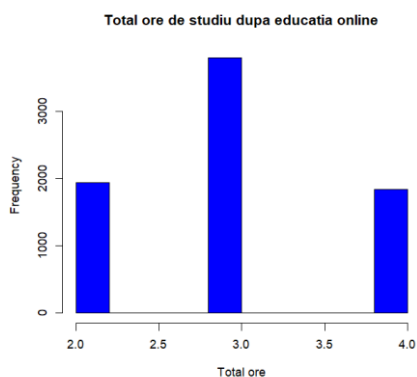
- **total_h_study_b_onl**: numărul minim de ore acordate de un student pentru învățat înainte de educația online a fost de 3 ore pe zi, în timp ce maximum de ore a fost de 6 ore. numărul mediu de ore acordate de un student pentru învățat înainte de educația online este de 4,5 ore;

- **total_h_study_a_onl**: numărul minim de ore acordate de un student pentru învățat după educația online a fost de 2 ore pe zi, în timp ce maximum de ore a fost de 4 ore. numărul mediu de ore acordate de un student pentru învățat înainte de educația online este aproximativ 3 ore;

- **gender**: 3380 de observații sunt de genul feminin iar 4206 masculin.

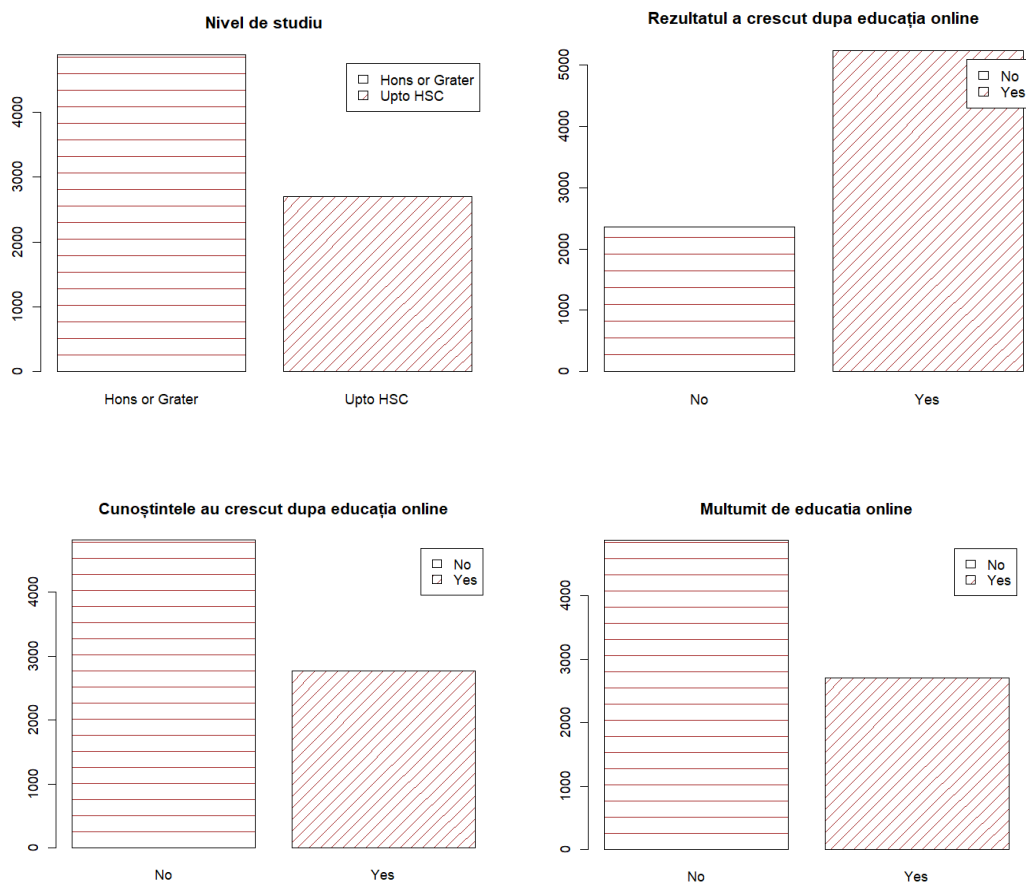
4.1. Analiza grafică a variabilelor numerice

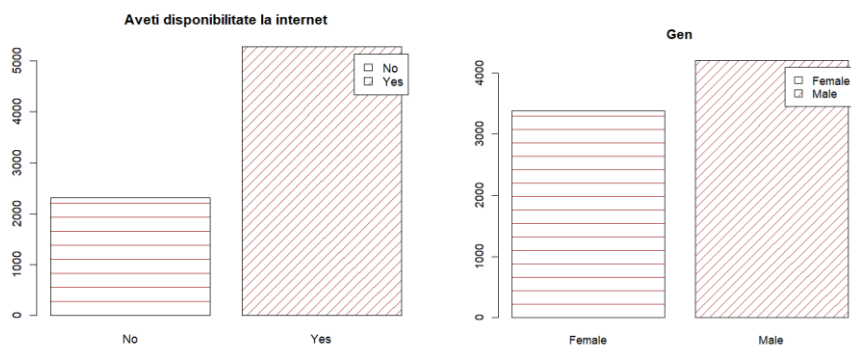




Se poate observa că histogramele descriu grafic tot ce a fost prezentat la subcapitolul anterior.

4.2. Analiza grafică a variabilelor nenumerice

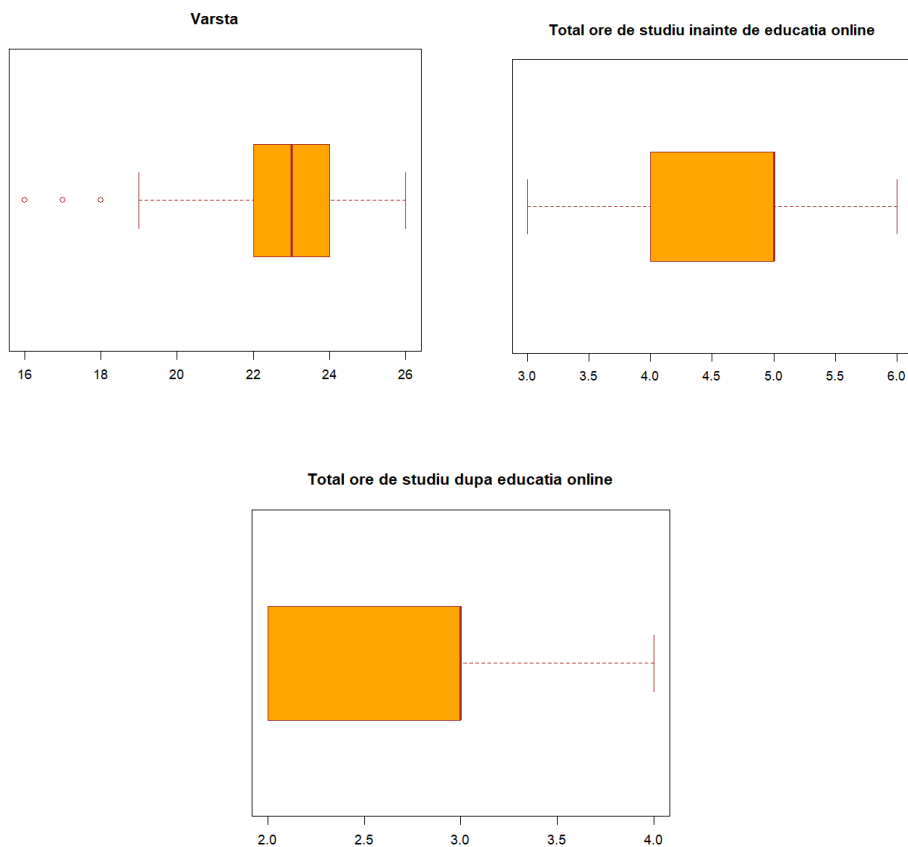




Se poate observa că histogramele descriu grafic tot ce a fost prezentat la subcapitolul anterior.

4.3. Identificarea outlierilor și tratarea acestora

Pentru a identifica valorile extreme pentru variabilele studiate se va folosi graficul Box plot.



Se remarcă faptul că doar variabila *age* are 3 valori extreme. Aceste valori nu vor fi eliminate deoarece nu afectează rețeaua neurală care urmează a fi efectuată.

5. Alegerea tipurilor de rețele neurale și prezentarea structurii acestora (SPSS)

Având în vedere tipul aplicației rețelei pe care dorim să o construim, respectiv aproximarea funcției de regresie, vom realiza în continuare patru rețele neurale, pentru a putea realiza și o comparație privind performanța acestor rețele, prin care vom estima legătura dintre variabila dependentă (rezultatul crescut după educația online) și nivelul de studiu al studenților (*lvl_study*), vârsta (*age*), cunoștințele crescute după educația online (*knowledge_a_onl*), nivelul de fericire pentru educația online (*happy*), accesul la internet (*internet_acces*), numărul total de ore acordate studiului înainte de educația online (*total_h_study_b_onl*), numărul total de ore acordate studiului după educația online (*total_h_study_a_onl*) și genul acestuia.

5.1. Multilayer Perceptron

Pentru prima rețea neurală, se va împărți setul de date în set de antrenare în care vor fi incluse 60% din înregistrările din bază, set de validare în care vor fi incluse 20% din înregistrările din bază și set de holdout în care vor fi restul înregistrărilor. Și se va construi mai departe o rețea neurală Multilayer Perceptron în care arhitectura rețelei va fi realizată automat. În urma construirii primei rețele neurale, au rezultat următoarele în SPSS.

Case Processing Summary

		N	Percent
Sample	Training	5015	60.1%
	Testing	1669	20.0%
	Holdout	1654	19.8%
Valid		8338	100.0%
Excluded		445	
Total		8783	

Din output putem observa cum sunt împărțite înregistrările din baza de date. Astfel, vedem că în setul de antrenament sunt 5015 de observații, iar în celelalte seturi sunt 1669 în setul de test, respectiv 1654 de observații în Holdout.

Network Information			
Input Layer	Factors	1	lvl_study
		2	knowledge_a_onl
		3	happy
		4	internet_acces
		5	gender
	Covariates	1	age
		2	total_h_study_b_onl
		3	total_h_study_a_onl
	Number of Units ^a		14
	Rescaling Method for Covariates		Standardized
Hidden Layer(s)	Number of Hidden Layers		1
	Number of Units in Hidden Layer 1 ^a		8
	Activation Function		Hyperbolic tangent
Output Layer	Dependent Variables	1	result_a_onl
	Number of Units		3
	Activation Function		Softmax
	Error Function		Cross-entropy

a. Excluding the bias unit

În cel de-al doilea output obținut sunt prezentate informațiile despre formarea rețelei neurale, în care avem numărul de variabile categoriale precum și numărul de variabile numerice. De asemenea avem afișat, numărul neuronilor de intrare, acestea fiind în număr de 14, structura rețelei fiind compusă dintr-un singur strat ascuns cu un număr de 8 neuroni pe acest strat, iar metoda de scalare a variabilelor numerice independente este cea de standardizare, iar funcția de activare a rețelei pentru neuronul de ieșire este *Softmax* prin care ia un vector de argumente cu valori reale și îl transformă într-un vector ale cărui elemente se încadrează în intervalul (0, 1) și suma 1. Softmax este disponibil numai dacă toate variabilele dependente sunt categorice.

Cea de-a doua rețea neurală va fi tot o rețea Multilayer Perceptron și avea setul de date împărțit la fel ca la prima rețea. Iar construirea acesteia se va realiza tot automat doar că acum numărul de straturi ascunse va fi setat pe doi. Mai jos putem vedea rezultatele, pentru descrierea acestei rețele, din SPSS.

Case Processing Summary			
		N	Percent
Sample	Training	5019	60.2%
	Testing	1622	19.5%
	Holdout	1697	20.4%
Valid		8338	100.0%
Excluded		445	
Total		8783	

În setul de antrenament sunt 5019 de observații (60,2%), un număr de 1622 pentru testing, respectiv 1697 pentru holdout.

Network Information

Input Layer	Factors	1	lvl_study
		2	knowledge_a_onl
		3	happy
		4	internet_acces
		5	gender
	Covariates	1	age
		2	total_h_study_b_onl
		3	total_h_study_a_onl
	Number of Units ^a		14
	Rescaling Method for Covariates		Standardized
Hidden Layer(s)	Number of Hidden Layers		2
	Number of Units in Hidden Layer 1 ^a		8
	Number of Units in Hidden Layer 2 ^a		6
	Activation Function		Hyperbolic tangent
Output Layer	Dependent Variables	1	result_a_onl
	Number of Units		3
	Activation Function		Softmax
	Error Function		Cross-entropy

a. Excluding the bias unit

Rețeaua creată are tot 14 neuroni de intrare ca în cazul primei rețele, diferit este numărul de straturi ascunse, acesta fiind egal cu doi, iar pe fiecare din aceste două straturi există câte un număr diferit de neuroni, pe primul strat ascuns sunt 8 neuroni, iar pe cel de-al doilea sunt 6 neuroni. La fel ca și în cazul primei rețele, metoda de scalare a variabilelor independente numerice este standardizarea, iar funcția de activare pentru neuronul de ieșire este *Identity*.

5.2. Radial Bias Function

La fel ca și celelalte două rețele, setul de date o să fie împărțit în aceeași manieră pentru ambele rețele, setul de date împărțit în set de antrenare în care vor fi incluse 60% din înregistrările din bază, set de validare în care vor fi incluse 20% din înregistrările din bază și set de holdout în care vor fi restul înregistrărilor.

Mai jos găsim descrierea primei rețele neurale este estimată cu ajutorul unui număr de neuroni ales dintr-un interval ales automat.

Case Processing Summary

		N	Percent
Sample	Training	4942	59.3%
	Testing	1712	20.5%
	Holdout	1684	20.2%
Valid		8338	100.0%
Excluded		445	
Total		8783	

În setul de antrenament sunt 4942 de observații (59,3%), iar în celelalte seturi sunt 1712 pentru testing, respectiv 1684 pentru holdout.

Network Information			
Input Layer	Factors	1	lvl_study
		2	knowledge_a_onl
		3	happy
		4	internet_access
		5	gender
	Covariates	1	age
		2	total_h_study_b_onl
		3	total_h_study_a_onl
	Number of Units		14
	Rescaling Method for Covariates		Standardized
Hidden Layer	Number of Units		7 ^a
	Activation Function		Softmax
Output Layer	Dependent Variables	1	result_a_onl
	Number of Units		3
	Activation Function		Identity
	Error Function		Sum of Squares

a. Determined by the testing data criterion: The "best" number of hidden units is the one that yields the smallest error in the testing data.

În tabelul "Network Information" găsim structura celei de-a treia rețele estimate, în care putem vedea numărul de 14 neuroni de intrare, numărul de neuroni prin care se atinge cea mai mică valoare a erorii, din stratul ascuns, respectiv 7, precum și metoda de scalare a datelor și funcțiile de activa de la nivelul fiecărui strat din rețea. În cazul acesta, funcția de activare de la nivelul stratului ascuns diferă față de funcția de activare de la nivelul stratului ascuns al celorlalte rețele estimate mai devreme.

Pentru estimarea celei de-a patra rețea vom folosi tot metoda de generarea automată a structurii, doar că acum vom specifica un interval de valori, în care să fie cuprins numărul de neuroni de pe stratul ascund, egal cu (1;500) de neuroni, din care se va alege automat un număr.

Case Processing Summary			
		N	Percent
Sample	Training	4979	59.7%
	Testing	1749	21.0%
	Holdout	1610	19.3%
Valid		8338	100.0%
Excluded		445	
Total		8783	

În setul de antrenament sunt 4979 de observații (59,7%), iar în celelalte seturi au un număr de 1749 pentru testing, respectiv 1610 pentru holdout.

Network Information

Input Layer	Factors	1	lvl_study
		2	knowledge_a_onl
		3	happy
		4	internet_acces
		5	gender
	Covariates	1	age
		2	total_h_study_b_onl
		3	total_h_study_a_onl
	Number of Units		14
	Rescaling Method for Covariates		Standardized
Hidden Layer	Number of Units		17 ^a
	Activation Function		Softmax
Output Layer	Dependent Variables	1	result_a_onl
	Number of Units		3
	Activation Function		Identity
	Error Function		Sum of Squares

a. Determined by the testing data criterion: The "best" number of hidden units is the one that yields the smallest error in the testing data.

Se observă faptul că tabelul de mai sus prezintă o diferență mare de straturi ascunse, în număr de 17, față de ultima rețea neuronală.

Vom vedea mai departe cât de bune sunt aceste rețele neurale pentru a explica legătura dintre variabila dependentă *result_a_onl* și restul variabilelor.

6. Analiza performanței rețelelor (SPSS)

În tabelul "Model Summary" sunt prezentate informații despre rezultatele aplicării rețelei pe fiecare din cele trei seturi. Eroarea relativă este constantă în cadrul eșantioanelor de antrenament, testare și holdout, ceea ce vă oferă o anumită încredere că modelul nu este supraestimat și că eroarea în cazurile viitoare calculate de rețea va fi aproape de eroarea raportată în acest tabel.

În graficul "Normalized Importance" vedem ordinea variabilelor care au cele mai mari influențe pentru variabila noastră dependentă.


6.1. Analiza performanței rețelei Multilayer Perceptron cu un singur strat ascuns și 8 neuroni pe stratul ascuns

Model Summary		
Training	Cross Entropy Error	3536.581
	Percent Incorrect Predictions	32.4%
	Stopping Rule Used	1 consecutive step(s) with no decrease in error ^a
	Training Time	0:00:00.31
Testing	Cross Entropy Error	1202.452
	Percent Incorrect Predictions	33.7%
Holdout	Percent Incorrect Predictions	35.1%

Dependent Variable: result_a_onl

a. Error computations are based on the testing sample.

Deși eroarea relativă este aproximativ constantă pe cele trei seturi, valoarea acesteia este destul de ridicată, predicția incorectă pentru setul training fiind de 32,4%, pentru testing de 33,7%, iar pentru holdout de 35,1%, ceea ce ne indică faptul că puterea de predicție nu este una tocmai puternică.



Variabila care are cea mai mare influență asupra rezultatului crescut după educația online a studenților este variabila *gender* (gen). Aceasta este urmată de vârstă (*age*).


6.2. Analiza performanței rețelei Multilayer Perceptron cu 2 straturi ascunse: primul strat ascuns are 8 neuroni, iar al doilea strat ascuns are 6 neuroni

Model Summary		
Training	Cross Entropy Error	3605.747
	Percent Incorrect Predictions	32.9%
	Stopping Rule Used	1 consecutive step(s) with no decrease in error ^a
	Training Time	0:00:00.20
Testing	Cross Entropy Error	1145.534
	Percent Incorrect Predictions	32.9%
Holdout	Percent Incorrect Predictions	34.6%

Dependent Variable: result_a_onl

a. Error computations are based on the testing sample.

La fel ca rețeaua de mai sus, eroarea relativă este aproximativ constantă pe cele trei seturi, valoarea acesteia fiind destul de ridicată. Predicția incorectă pentru setul training este de 32,9%, pentru testing de 32,9%, iar pentru holdout de 34,6%, ceea ce ne indică faptul că puterea de predicție nu este una tocmai puternică.



Variabila care are cea mai mare influență asupra rezultatului crescut după educația online a studenților este variabila *total_h_study_b_onl* (ore dedicate studiului înainte de educația online). Aceasta este urmată de vârstă (*age*).

Observăm că variabila care influențează cel mai mult variabila dependentă nu este aceeași ca la rețeaua cu un singur strat ascuns și 8 neuroni pe stratul ascuns.

6.3. Analiza performanței rețelei Radial Bias Function cu 7 neuroni pe stratul ascuns


Model Summary

Training	Sum of Squares Error	1106.394
	Percent Incorrect Predictions	32.7%
	Training Time	0:00:00.70
Testing	Sum of Squares Error	392.888 ^a
	Percent Incorrect Predictions	34.2%
Holdout	Percent Incorrect Predictions	33.7%

Dependent Variable: result_a_onl

a. The number of hidden units is determined by the testing data criterion: The "best" number of hidden units is the one that yields the smallest error in the testing data.

Eroarea relativă pentru setul training este de 32,7%, pentru testing de 34,2%, iar pentru holdout de 33,7%, ceea ce ne indică faptul că puterea de predicție nu este una tocmai puternică.



Variabila care are cea mai mare influență asupra rezultatului crescut după educația online a studenților este variabila *age* (vârstă). Aceasta este urmată de nivelul de studiu (*lvl_study*).


6.4. Analiza performanței rețelei Radial Bias Function cu 17 neuroni pe stratul ascuns

Model Summary		
Training	Sum of Squares Error	1119.163
	Percent Incorrect Predictions	33.0%
	Training Time	0:00:47.85
Testing	Sum of Squares Error	395.821 ^a
	Percent Incorrect Predictions	33.4%
Holdout	Percent Incorrect Predictions	33.7%

Dependent Variable: result_a_onl

a. The number of hidden units is determined by the testing data criterion: The "best" number of hidden units is the one that yields the smallest error in the testing data.

Eroarea relativă pentru setul training este de 33%, pentru testing de 33,4%, iar pentru holdout de 33,7%, ceea ce ne indică faptul că puterea de predicție nu este una tocmai puternică.



Variabila care are cea mai mare influență asupra rezultatului crescut după educația online a studenților este variabila *age* (varsta). Aceasta este urmată de *knowledge_a_onl*.

Cel mai bun model este analizat cu Radial Bias Function și este o rețea cu 17 neuroni pe stratul ascuns. Acest model este cel mai bun deoarece valorile sunt mai apropiate între ele decât la celelalte rețele () chiar dacă la rețeaua Multilayer Perceptron cu 2 straturi ascunse cu 8 neuroni pe H1 și 6 neuroni pe H2, procentele de predicție incorecte pentru seturile de date training, test și holdout au valori mai mici ca la Radial Bias Function cu 17 neuroni pe stratul ascuns.

7. Alegerea tipurilor de rețele neurale și prezentarea structurii acestora (R)


Așa cum au fost estimate rețelele neurale în SPSS, cu ajutorul programului R vom estima câteva rețele neurale Multilayer Perceptron cu ajutorul programului R.

În programul R, instalăm pachetul *neuralnet* pentru a lucra cu rețelele neuronale. Pachetul *neuralnet* necesită o matrice sau un cadru de date complet numeric. De asemenea, se va utiliza funcția *set.seed()* pentru a genera numere aleatorii.

Pentru început se transformă variabilele factor în variabile numerice pentru a putea realiza scalarea datelor, după care se va împărți setul de date în set de învățare și set de validare, în care setul de antrenare are o proporție de 70% din totalul înregistrărilor, iar setul de testare are un procent de 30% din înregistrările setului principal de date.


7.1. Rețea neurală în R cu un strat ascuns și 4 neuroni pe stratul ascuns

Iar mai jos avem construită afișată prima rețea neurală în R cu 4 neuroni de pe stratul ascuns și 5 neuroni de intrare.



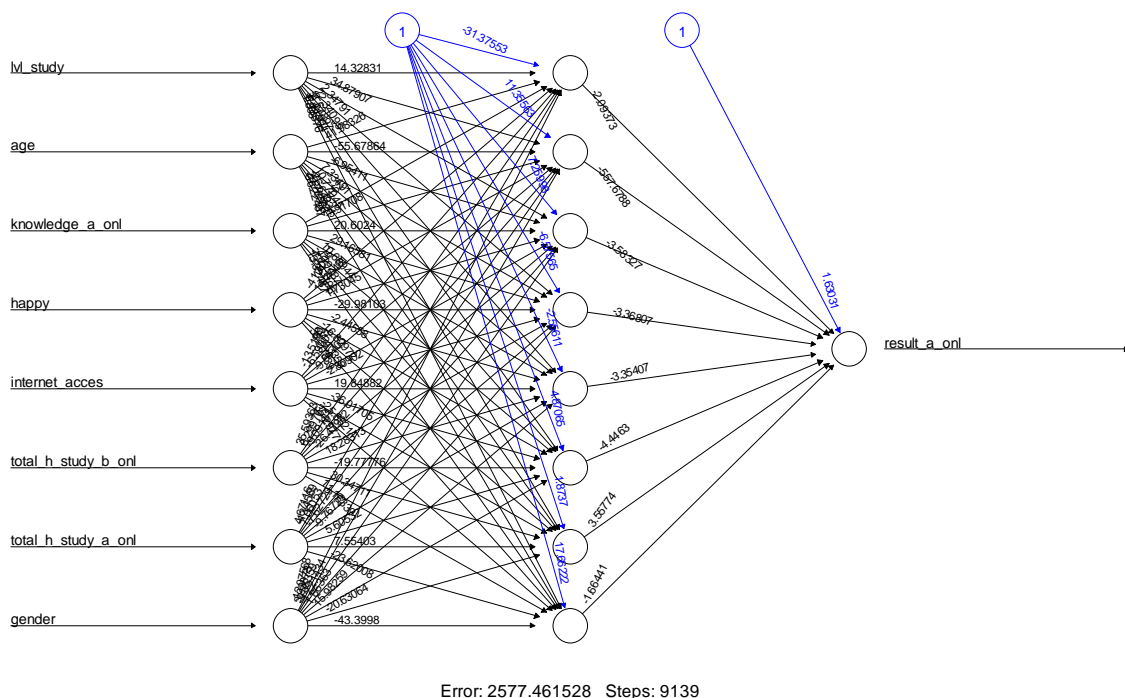
Din graficul de mai sus putem vedea prima rețea neurală creată în R. Aceasta are pe stratul de intrare 8 neuroni, pe stratul ascuns are 4 neuroni iar pe stratul de ieșire, după cum era și de așteptat, un singur neuron.

7.2. Rețea neurală în R cu un strat ascuns și 2 neuroni pe stratul ascuns



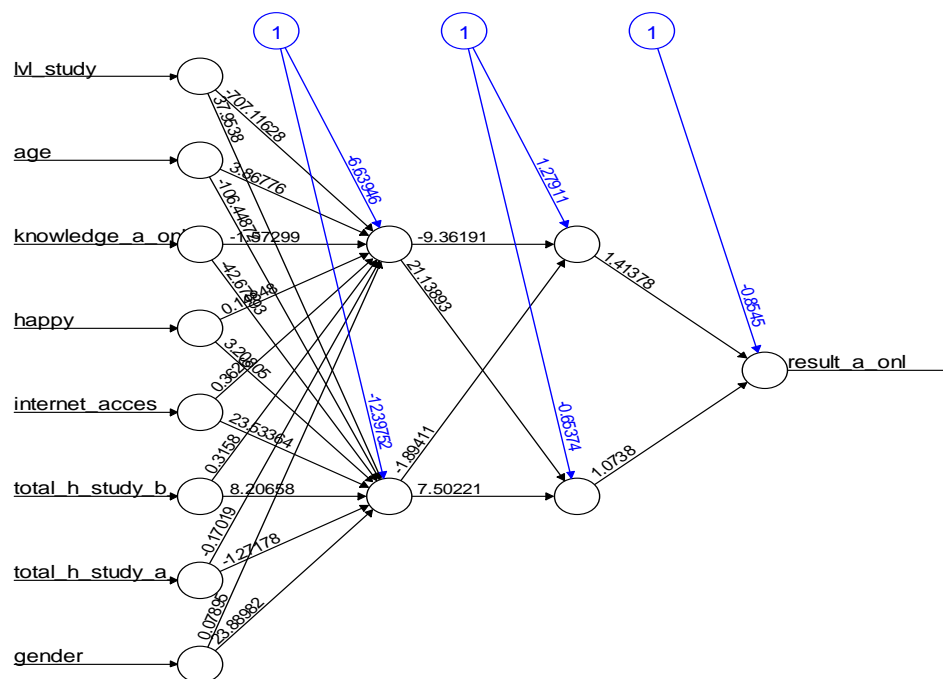
La fel ca și în prima rețea estimată în R, aceasta are tot 8 neuroni de intrare și unul de ieșire, diferit este numărul de neuroni de pe stratul ascuns, acesta fiind egal cu 2.

7.3. Rețea neurală în R cu un strat ascuns și 2 neuroni pe stratul ascuns



Numărul de neuroni de pe stratul ascuns din această rețea este mai mare cu patru față de precedenta rețea.

7.4. Rețea neurală în R cu 2 straturi ascunse si 2 neuroni pe stratul H1 și 2 pe H2



Error: 556.040179 Steps: 37575

Această rețea este formată din 2 straturi ascunse. Fiecare strat ascuns este compus din 2 neuroni. Liniile albastre afișează termenul de părtinire (*constant* într-o ecuație de regresie).

8. Analiza performanței rețelelor (R)

În acest capitol vom analiza performanța fiecărei rețele estimate cu un singur strat ascuns din capitolul 7 și vom realiza de asemenea o comparație pentru a vedea care din cele două rețele este mai potrivită pentru datele noastre.

	Rețea MPL cu 4 neuron pe stratul ascuns	Rețea MPL cu 2 neuron pe stratul ascuns	Rețea MPL cu 8 neuron pe stratul ascuns
Eroarea rețelei	2595.758161	2609.267225	2577.461528
Pași	16251	4085	9139

În tabelul de mai sus sunt prezentate erorile rețelelor și numărul de pași necesari în crearea lor. Putem vedea că pentru prima rețea, cea cu 4 neuron pe stratul ascuns, eroare este de 2595.758161, pentru rețeaua cu 2 neuron pe stratul ascuns eroarea este egală cu 2609.267225, pentru rețeaua cu 8 neuron pe stratul ascuns eroarea este egală cu 2577.461528, iar pentru rețeaua cu 2 neuron pe ambele straturi ascunse eroarea este 556.04179.

Făcând o comparație între cele patru erori, putem spune că nu există diferențe foarte mari între acestea. Potrivit regulii care spune că cea mai mică eroare oferă o rețea mai bună analizei, rețeaua cu 8 neuron pe stratul ascuns este mai bună decât celelalte trei rețele.

Numărul de pași pentru construirea rețelelor arată că rețeaua cea mai ușor de construit a fost rețeaua cu 2 neuron pe stratul ascuns așa cum era și de așteptat din cauza numărului redus de straturi ascunse și de neuronii acestuia.

Astfel putem să ne pronunțăm cu privire la performanța celor patru rețele comparând corectitudinea rețelei și timpul de realizare a rețelelor. Din perspectiva acurateții putem spune că rețeaua cu 8 neuron pe stratul ascuns este mai potrivită pentru aproximarea funcției de regresie pentru datele noastre. Dacă un criteriu pentru a alege rețeaua ar fi și timpul de realizare, atunci am fi mers mai departe cu rețeaua cu 2 neuron pe stratul ascuns pentru că diferența dintre erori nu este foarte mare având în vedere de câți pași a fost nevoie pentru construirea acesteia.

9. Predicția rețelei neurale

În acest capitol doresc să estimez puterea de predicție pentru rețeaua cu 2 neuroni pe stratul ascuns, pentru rețeaua cu 4 neuroni pe stratul ascuns și pentru rețeaua cu 8 neuroni pe stratul ascuns.

```
> #####
> pred1 <- compute(nn_1_4 , data[-train ,2:9] )
> r1 <- ifelse( pred1$net.result <= 0.5 , -1, 1)
> table(sign(r1),sign(data[-train ,1]) ,
+       dnn =c(" Predicted " , " Observed "))
      Observed
Predicted  -1    1
      -1  698 1544
       1    6   28
> error_rate = (1- sum( sign(r1) == sign(
+ data[-train ,1]) )/2276 )
> round( error_rate ,3)
[1] 0.681
> #####
> pred2 <- compute(nn_1_2 , data[-train ,2:9] )
> r2 <- ifelse( pred2$net.result <= 0.5 , -1, 1)
> table(sign(r2),sign(data[-train ,1]) ,
+       dnn =c(" Predicted " , " Observed "))
      Observed
Predicted  -1    1
      -1  704 1572
       1    6   28
> error_rate = (1- sum( sign(r2) == sign(
+ data[-train ,1]) )/2276 )
> round( error_rate ,3)
[1] 0.691
```

```
> #####
> pred3 <- compute(nn_1_8 , data[-train ,2:9] )
> r3 <- ifelse( pred3$net.result <= 0.5 , -1, 1)
> table(sign(r3),sign(data[-train ,1]) ,
+       dnn =c(" Predicted " , " Observed "))
      Observed
Predicted  -1    1
      -1  676 1486
       1   28   86
> error_rate = (1- sum( sign(r3) == sign(
+ data[-train ,1]) )/2276 )
> round( error_rate ,3)
[1] 0.665
```

Din output-urile de mai sus se poate observa că matricea de confuzie pentru rețeaua cu 2 neuroni pe stratul ascuns prezintă valori prezise eronat. Rata de eroare pentru rețeaua cu 8 neuroni pe stratul ascuns este cea mai scăzută dintre toate.

Matricea de confuzie pentru rețeaua cu 4 neuroni pe stratul ascuns arată că 698 de valori au fost previzionate corect pentru răspunsul "-1", iar 28 de valori au fost previzionate corect pentru răspunsul "1".

Matricea de confuzie pentru rețeaua cu 8 neuroni pe stratul ascuns arată că 676 de valori au fost previzionate corect pentru răspunsul "-1", iar 86 de valori au fost previzionate corect pentru răspunsul "1".

Concluzii

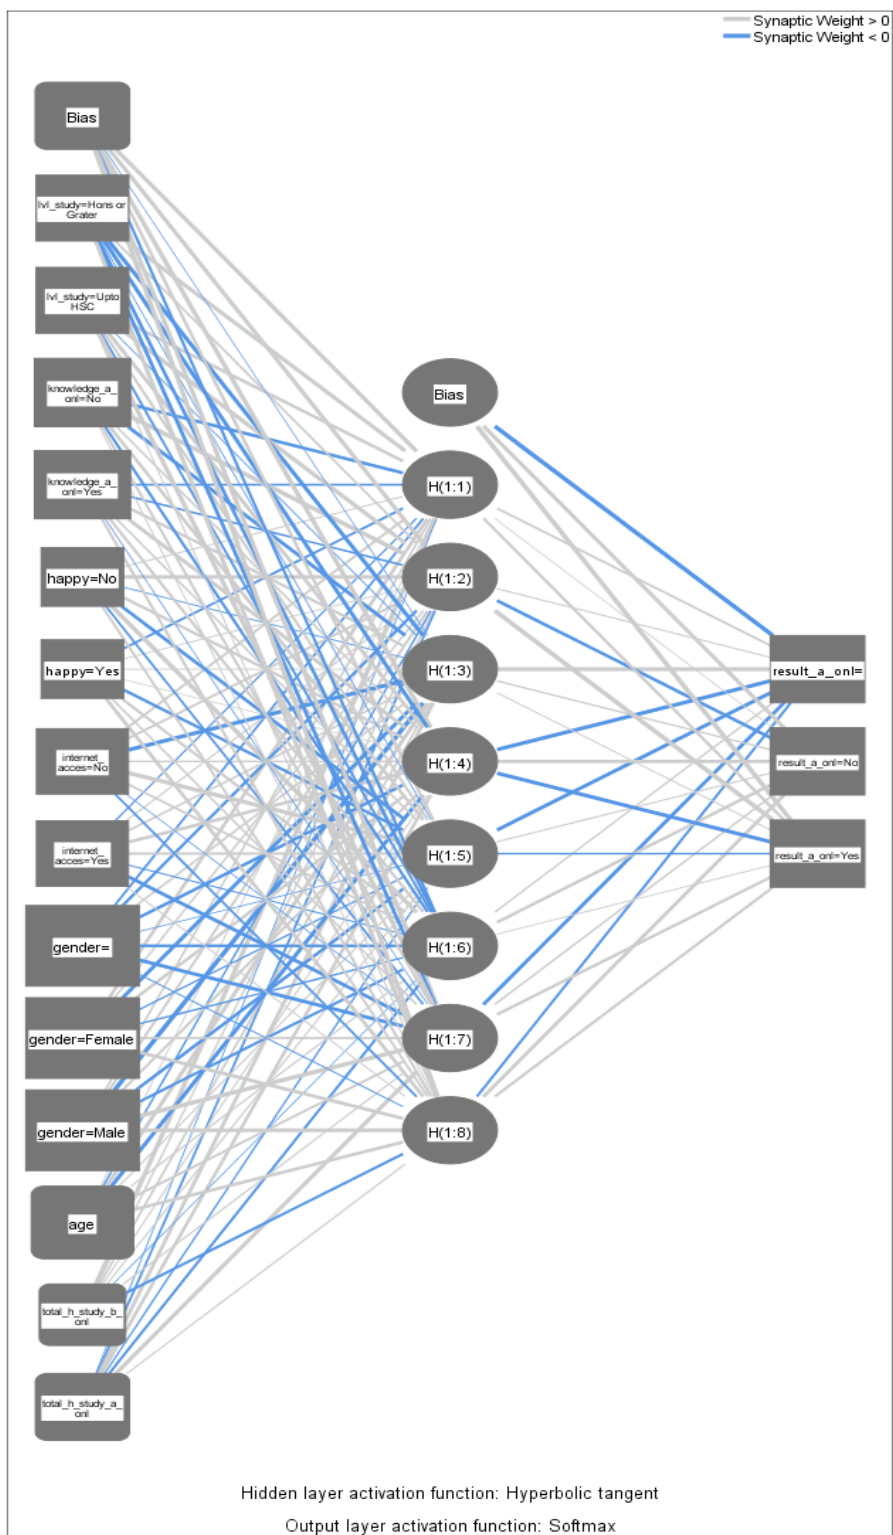
Pe parcursul proiectului, am reușit să îndeplinesc obiectivul propus de a prezice performanța pe care îl poate obține un student după trecerea la educația online în funcție de nivelul de studiu, vârsta, cunoștințele acumulate pe parcursul învățământului online, starea de fericire pentru trecerea la educația online, accesul la internet, genul, numărul de ore dedicat învățării înainte de educația online dar și după.

Pentru obținerea celor mai bune predicții am estimat în SPSS două rețele de tip Multilayer Perceptron și două de tip Radial Bias Function. Cel mai bun model este analizat cu Radial Bias Function și este o rețea cu 17 neuroni pe stratul ascuns. Acest model a fost ales datorită faptului că procentul de predicții incorecte este foarte apropiat între cele trei seturi de date în care a fost împărțită baza de date inițial: training cu 60%, testing cu 20% și holdout cu 20%.

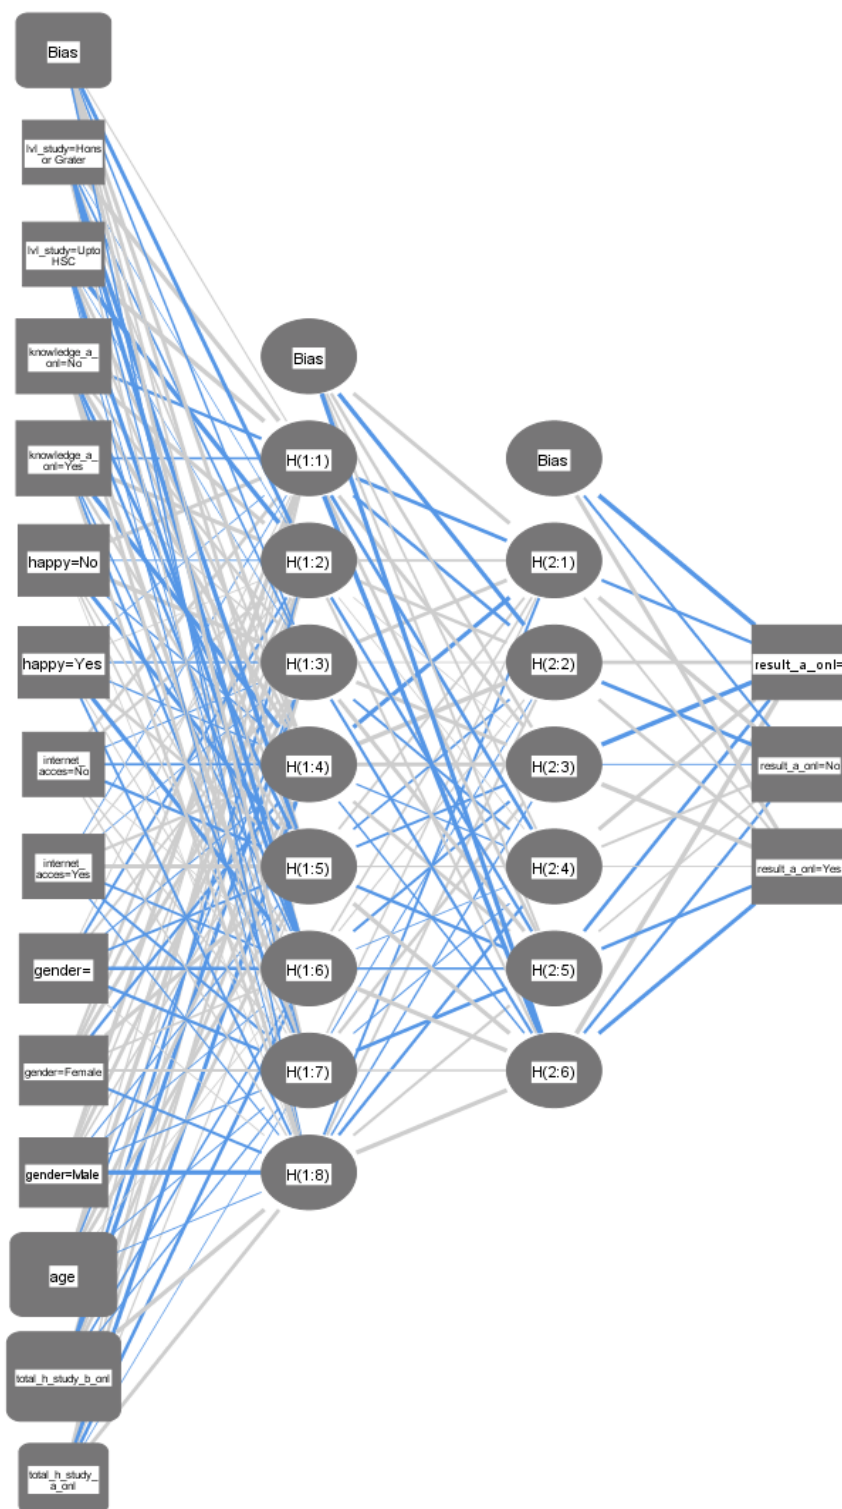
În capitolul 7, am estimat patru rețele Multilayer Perceptron în programul R. Toate rețelele au avut câte 8 neuroni pe stratul de intrare. Diferența dintre acestea a dat-o numărul de neuroni pe stratul ascuns dar și numărul de straturi ascunse. Prima rețea avea 4 neuroni pe stratul ascuns, a doua rețea 2 neuroni pe stratul ascuns, a treia rețea 8 neuroni pe stratul ascuns iar ultima rețea era formată din 2 straturi ascunse a câte 2 neuroni pe fiecare strat ascuns. Rețeaua cu 8 neuroni pe stratul ascuns este mai bună în comparație cu rețeaua cu 2 sau 4 neuroni pe stratul ascuns cu o eroare de 0,665.

În concluzie, rețelele neuronale sunt flexibile și pot fi utilizate cu probleme de clasificare, și, de asemenea, sunt preferate ca o abordare alternativă în locul metodelor statistice convenționale.

ANEXĂ



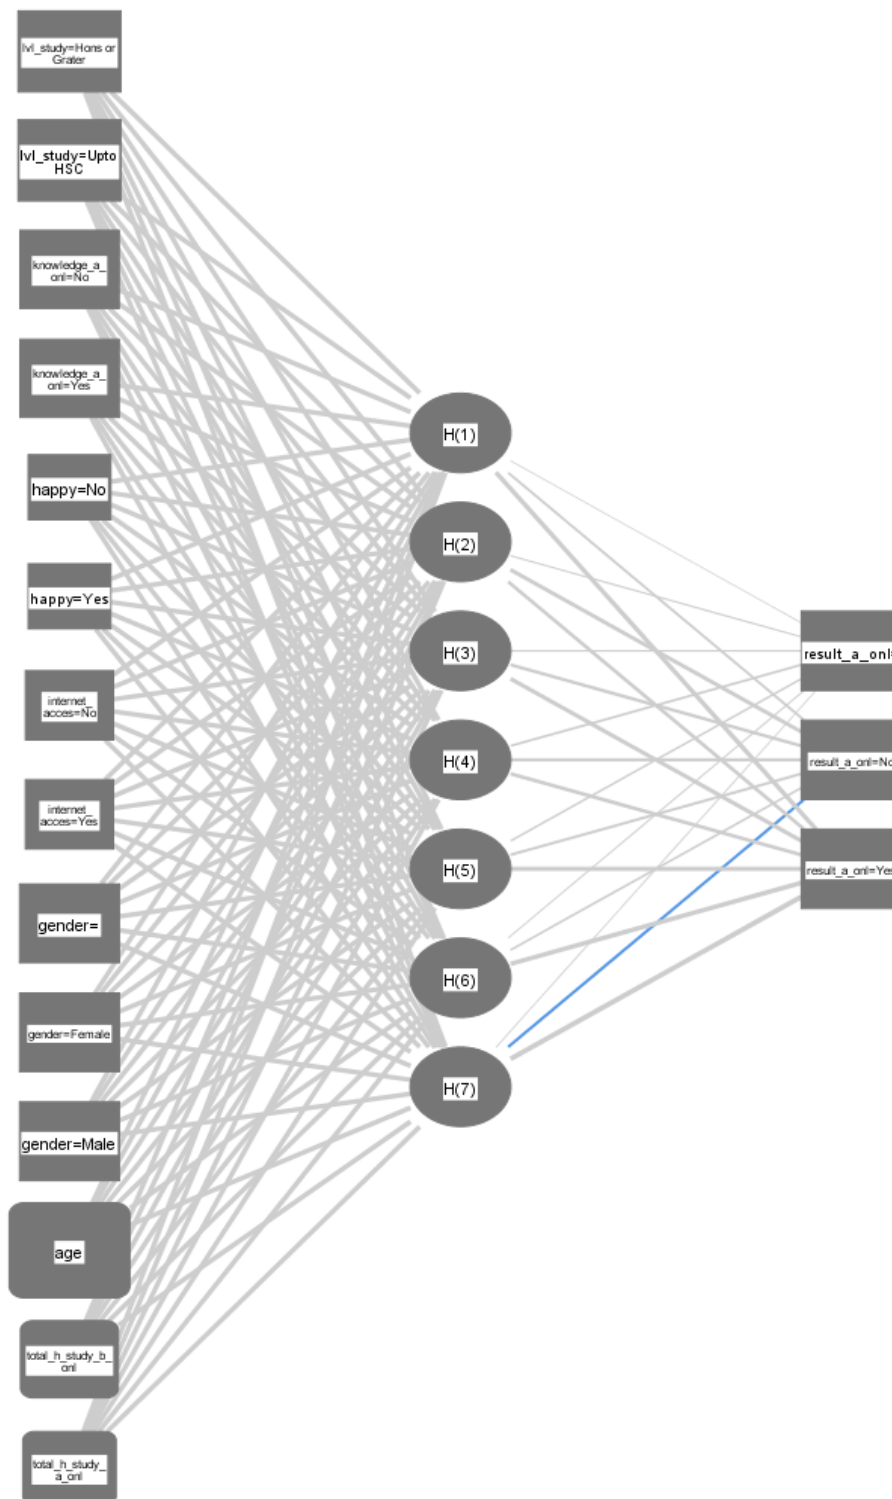
— Synaptic Weight > 0
 — Synaptic Weight < 0



Hidden layer activation function: Hyperbolic tangent

Output layer activation function: Softmax

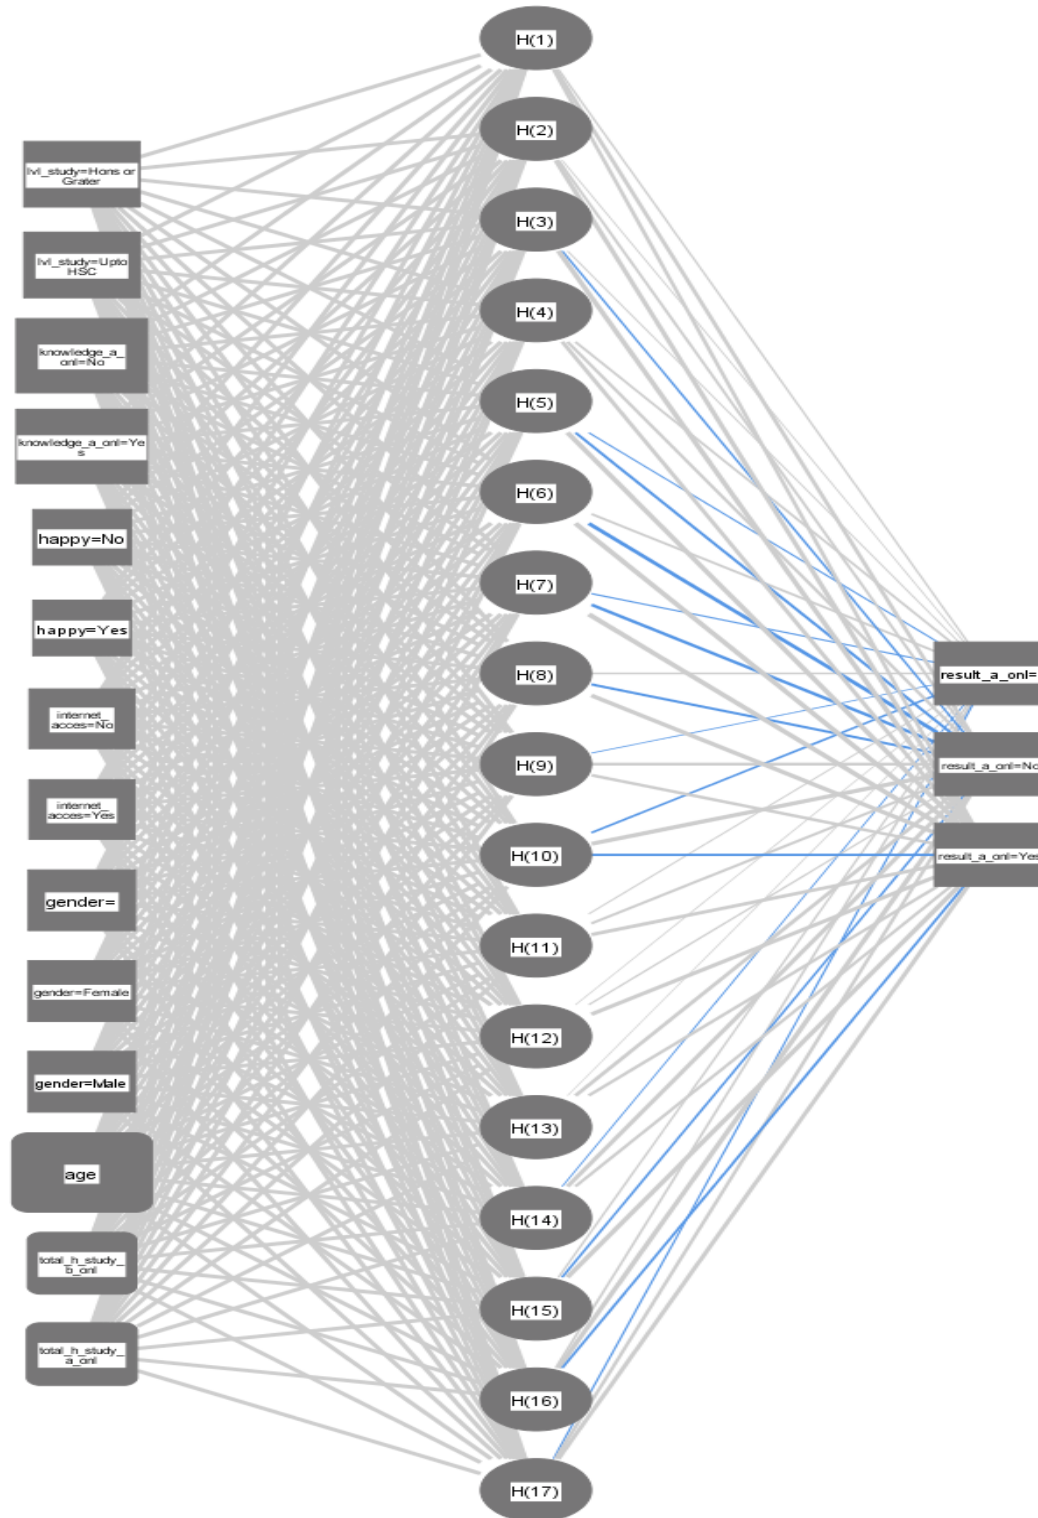
— Synaptic Weight > 0
 — Synaptic Weight < 0



Hidden layer activation function: Softmax

Output layer activation function: Identity

— Synaptic Weight > 0
 — Synaptic Weight < 0



Hidden layer activation function: Softmax

Output layer activation function: Identity

Bibliografie

Articole din reviste:

1. Abu Tair, M. M. & El-Halees, A. M., *Mining educational data to improve students' performance: a case study*. Mining educational data to improve students' performance: a case study, Vol. 2(2)
2. AlHamad AQM , *Acceptance of e-learning among university students in UAE: a practical study*. Int J Electr Comput Eng, 2020, Vol. 10(4), pp. 3660–3671
3. Cradler, J. , McNabb, M., Freeman, M., Burchett, R., *How does technology influence student learning*, Learning and Leading with Technology, 2002 vol. 29, no. 8, pp. 46–49.
4. Faheem, M., Shah, S., B., H., Butt, R., A., *Smart grid communication and information technologies in the perspective of Industry 4.0: opportunities and challenges*, Computer Science Review, 2018, Vol. 30, pp. 1–30.
5. Oyelade, O., J. , Oladipupo, O., O., Obagbuwa, I., C., *Application of k means clustering algorithm for prediction of students academic performance*, 2010.
6. Romero, C., Ventura, S., *Educational data mining: a review of the state of the art*. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2010, Vol. 40(6), pp. 601–618.
7. Sokkheyand and, P., Okazaki, T., *Developing web-based support systems for predicting poor-performing students using educational data mining techniques*, Studies, 2020, Vol. 11, no. 7.

Site-uri web:

1. International Publishers Association. Publishers Amid COVID-19 Pandemic. Disponibil online: <https://www.internationalpublishers.org/covid-reaction/168-covid-19/966-publishers-act-amid-covid19-pandemic>
2. UNESCO. Education: From Disruption to Recovery. Disponibil online: <https://en.unesco.org/covid19/educationresponse>